

Cómo funciona un LLM

SESIÓN 2 DE 8 · DÍA 1: QUÉ ES Y CÓMO FUNCIONA · 2 H EN VIVO · PCR · CGC ·
TECPETROL · ANDES PETROLEUM



Tokens y predicción

BLOQUE 1 DE 5 · **33 MIN**



Esta sesión

BLOQUE	TIEMPO	QUÉ HACEMOS
Tokens y predicción	33 min	Los dos primeros laboratorios de la página, y un modelo real abierto en el navegador
De predecir palabras a un asistente general	20 min	Cómo aprende de texto sin que nadie lo etiquete, la escala, la etapa que lo vuelve asistente, y de ahí a los agentes
Contexto: la memoria de trabajo	15 min	La ventana de contexto en vivo con el laboratorio de la página
Pausa	10 min	Dejá el chatbot abierto: lo usás al volver
Alucinaciones en vivo	30 min	Lo hacemos alucinar: primero el instructor, después cada uno con una pregunta de su especialidad
Cierre: cuatro maneras de fallar, ¿cambiarías tu definición?, tarea	12 min	La hoja de ruta del curso, tu definición de la mañana revisada, tres prácticas para mañana y la tarea de cinco minutos



Al final de esta sesión van a poder

- Entender qué es un **token**, cómo el modelo predice el siguiente y qué controla la temperatura
- Explicar cómo aprende de texto **sin etiquetas** y por qué termina siendo de propósito general
- Ver qué entra en la **ventana de contexto** y qué se cae
- Derivar de esa mecánica **por qué alucina**



El modelo lee tokens

Antes de procesar nada, parte el texto en pedazos. Pueden ser palabras enteras, sílabas o letras sueltas.

Lo frecuente en internet entra como un solo token. Lo técnico, y casi todo el español, se parte en varios.



Antes de mirar: adiviná

¿En cuántos tokens parte el modelo la frase **perforación direccional**? ¿2, 4, 6, u 8 o más?

Un número en el chat, cuando Martín diga "ya".



Ahora abrilo: laboratorio de tokens

Está en la página de la sesión 2. Empezá por **perforación direccional**.



Tres consecuencias que ya vieron sin saberlo

- **Cuenta mal las letras** de una palabra, porque lo que ve son pedazos
- **El español rinde menos:** la misma frase cuesta más tokens que en inglés
- **El uso por programa se cobra por token**, así que trabajar en español sale más caro



Una sola operación, repetida

Un **modelo grande de lenguaje** (LLM) hace una sola cosa.

Dado el texto hasta acá, le pone una probabilidad a cada token que podría seguir, elige uno, y vuelve a empezar. Mucha gente se imagina una base de datos de respuestas; lo que hay es **una máquina de continuar texto**.



Elegí vos el próximo token

El segundo laboratorio de la página. Movele a la temperatura y mirá qué cambia.



El mismo mecanismo, con un modelo real adentro

poloclub.github.io/transformer-explainer

GPT-2 corriendo en el navegador: tokens, atención y la probabilidad de cada candidato, en vivo.



La temperatura elige entre los candidatos que ya hay

Temperatura baja: gana casi siempre el más probable. Salida estable y repetitiva.

Temperatura alta: los poco probables tienen su oportunidad. Salida variada, a veces brillante y a veces disparatada.



¿En cuál de tus tareas querías la versión aburrida?

Una tarea tuya, en el chat, donde querías la misma respuesta cada vez.




De predecir palabras a un asistente general

BLOQUE 2 DE 5 · **20 MIN**




Tres maneras de aprender, y la de los LLM

Supervisado



Los ejemplos traen la respuesta: pozos con su tipo declarado. El modelo aprende a clasificar uno nuevo.

No supervisado



Los ejemplos vienen sin respuesta. El modelo arma grupos por su cuenta, y ponerles nombre queda para una persona.

Autosupervisado



La respuesta sale del propio dato: se tapa la palabra siguiente. Así se entrenan los LLM (modelos grandes de lenguaje).

Los pozos traían su tipo declarado; el texto trae la respuesta adentro, en la palabra siguiente.

Cada oración, un montón de ejercicios

Tercer laboratorio de la página: recorré la oración palabra por palabra.




Cada palabra mira a las demás

El **transformer** (2017) resuelve qué palabra sigue dejando que cada palabra mire a todas las otras y pese cuáles importan: eso es la **atención**.

En "la presión del reservorio cae porque", lo que viene depende de **presión** y de **reservorio** mucho más que de **la**.




Cuánto cómputo hizo falta para entrenar cada modelo



Cada línea es 1,000 veces la de abajo. Desde 2010, el cómputo creció 4.5 veces por año. Datos: Epoch AI (CC BY).

Dos etapas de tamaños muy distintos



La primera enseña a continuar textos; la segunda, mucho más chica, a responder como asistente.

De conversar a hacer

- **2024 · Piensa antes de responder.** o1 se entrenó con aprendizaje por refuerzo para razonar paso a paso antes de contestar
- **2025 · Usa herramientas.** Claude Code trabaja en la terminal: lee código, edita archivos, corre pruebas
- **2026 · Trabaja solo, y por más tiempo.** Los agentes se instalan en el escritorio, y completan tareas que a un experto le llevan horas


El mismo tipo de modelo general, con herramientas y un ciclo que le permite actuar.



Por qué termina siendo general

IA de propósito específico


un modelo por tarea



Cada modelo se entrena para una sola tarea.

IA de propósito general

un modelo, muchas tareas



La AGI (inteligencia artificial general), igualar a una persona en casi todo, es otra discusión: sesión 8.

Para predecir bien la palabra siguiente en cualquier texto, tiene que aprender un poco de todo.

Contexto: la memoria de trabajo

BLOQUE 3 DE 5 · **15 MIN**



La ventana de contexto es la memoria de trabajo

Todo lo que el modelo puede mirar para elegir el próximo token: tu pregunta, sus respuestas anteriores, los documentos que pegaste.

Tiene un tamaño máximo, medido en tokens. Lo que queda afuera, **no existe** para el modelo.



Achicá la ventana

mpodeley.github.io/curso-ia-energia · sesión 2

Baja el tamaño de la ventana y mirá cuál es el mensaje que se cae primero.



De ahí salen dos frustraciones conocidas

En una conversación larga, el principio se cae del escritorio. El modelo no avisa: sigue contestando con lo que le queda.

Y en un documento grande, lo que se cayó tampoco se busca solo. Hay que volver a pegarlo.



Qué hacer con esto un martes a la mañana

- **Conversación nueva por tarea:** lo de antes ocupa lugar en la ventana
- **Repetí la regla** cada tanto en una conversación larga: así vuelve a entrar en la ventana
- **Pegá el material:** lo que no está en la ventana, el modelo no lo tiene



Pausa · 10 min

Volvemos a la 1:18 del cronómetro. Dejá el chatbot abierto: lo usás al volver.



Alucinaciones en vivo

BLOQUE 4 DE 5 · **30 MIN**



Si solo continúa texto plausible, cuando no sabe no se calla

No tiene un mecanismo para detectarse. Genera la continuación más plausible igual.

Un número de norma que parece real, un paper que suena citable, una cifra de producción con tres decimales.



Una palabra: ¿qué te preocupa de que alucine?

Escribila en el chat.



Hagámoslo alucinar

Miren dos cosas: qué **seguro** suena, y cuánto tardamos en **verificarlo**.



Ahora vos: hacelo alucinar

Preguntale algo de **tu especialidad** que puedas verificar de memoria y sea público: una norma, una cifra del regulador, un nombre. Nada de tu empresa. Pegá la respuesta en el chat.



La salida de un LLM es un
borrador plausible: se verifica
antes de usarlo



Esto no se arregla con más cómputo

La ventana de contexto crece, los modelos mejoran y la frecuencia baja, pero el mecanismo sigue siendo el mismo.

Lo que sí se puede cambiar es **de dónde saca el material**, y eso es la sesión 5.



Cierre

BLOQUE 5 DE 5 · **12 MIN**



Las cuatro maneras de fallar

- **Inventa lo que no sabe:** de cómo genera el texto, token por token
· hoy
- **No hace lo que le pediste:** de cuánto control dan las instrucciones
· mañana
- **Está seguro y equivocado:** de lo que aprendió y de lo que no ·
sesión 5
- **Se olvida de lo que le dijiste:** de cuánto puede mirar a la vez · hoy
y sesión 6



¿Cambiarías tu definición?

A la mañana escribiste qué es la IA para vos. Con lo que viste de cómo funciona, ¿le agregarías o le sacarías algo?



Qué hacer con esto desde mañana

- **Tareas donde podés verificar rápido:** ahí rinde y el riesgo es bajo
- **Poné el material en la ventana:** pegá el texto que necesita
- **Desconfiá de todo número, cita o norma** que no hayas visto con tus ojos



Tarea para mañana

Traé **una tarea real de tu semana** que le pedirías a un chatbot.

Tres líneas: qué le pedirías, qué material tendrías que darle, y cómo sabrías si lo hizo bien.

Si ya tenés cuenta, probala (sin datos confidenciales) y anotá qué salió **mal**. Cinco minutos.



Mañana, sesiones 3 y 4: prompting y análisis asistido de datos

- Escribir prompts con **rol, contexto, tarea, formato y ejemplos**, sobre tu tarea
- Saber **qué información de la empresa no debe subirse** a un chatbot
- Del **reporte diario de la ARCH** a una tabla verificada, y una declinación sobre pozos reales



Nos vemos mañana

EL QUIZ, LOS RECURSOS Y LOS LABORATORIOS QUEDAN EN LA PÁGINA .
[MPODELEY.GITHUB.IO/CURSO-IA-ENERGIA](https://mpondeley.github.io/curso-ia-energia)