

Qué es esto y cómo funciona

DÍA 1 DE 4 · 4 H EN VIVO · PCR · CGC · TECPETROL · ANDES PETROLEUM

Apertura

BLOQUE 1 DE 9 · **15 MIN**



Hoy

BLOQUE	TIEMPO	QUÉ HACEMOS
Apertura: quiénes somos, regla entre empresas, entrada al sitio	15 min	Los dos instructores, una ronda de seis con nombre y empresa, la regla de confidencialidad, el ingreso con el PIN y el primer pulso
El mapa de cuatro capas	35 min	La historia de abajo, con ejemplos de la industria en cada capa. Las dos primeras las tocamos en vivo, con el duelo de declinación
Demos en vivo	30 min	El chatbot frente a tareas reales: resumir un paper, explicar un término, escribir un correo difícil. Y verlo fallar
Encuesta de relevamiento	12 min	La completamos juntos en vivo (ver abajo)
Discusión	15 min	Qué sorprendió y qué decepcionó de lo visto hasta acá
Pausa	10 min	Si te quedó la encuesta a medias, es el momento: se guarda sola



Al final del día van a poder

- Ubicar **data science**, **machine learning** e **IA generativa** en un solo mapa
- Ver en vivo qué puede y qué **no** puede hacer hoy un chatbot con tareas reales de la industria
- Entender qué es un **token**, cómo el modelo predice el siguiente, y derivar de ahí **por qué alucina**

Este es un curso de conducir, no de mecánica: de cómo funciona por dentro, solo lo que ayude a manejar mejor.

Quiénes somos

Matías Podeley dicta. Ingeniero del ITBA, dieciocho años en energía: cuatro de operación en Neuquén, simulación de yacimientos gigantes como Camisea y respaldo técnico a compras de activos por más de US\$ 300 millones. Buenos Aires.

Martín Alvarado lleva el chat, los pulsos y las rondas. Lo que escriban en el chat lo lee él, y él llama a cada uno cuando toca hablar.



Ronda: nombre, empresa y a qué te dedicás

Seis personas, medio minuto cada una. Sin datos de la empresa: solo el rol.



En estos ejercicios **no** usamos datos confidenciales de ninguna empresa

Hay cuatro empresas en la sala. Ni volúmenes reales de producción, ni nombres de contratos, ni información de partners: nada de eso va al chat ni a un chatbot gratuito. Los ejemplos salen de fuentes públicas: el reporte diario de la ARCH y el Capítulo IV.



Antes de empezar, entrá al sitio

`mpodeley.github.io/curso-ia-
energia`

Vamos a usar la página del día 1 varias veces hoy. El PIN del curso lo dicto en voz alta.



El mapa de cuatro capas

BLOQUE 2 DE 9 · 35 MIN



Para quien trabajó con
reservorios, nada de esto es **tan**
nuevo como parece



Cuatro capas, una historia conocida

- **Data science:** mirar datos, limpiarlos, graficarlos, sacar conclusiones
- **Machine learning:** en vez de escribir la fórmula, mostrás ejemplos y la máquina encuentra el patrón
- **Deep learning:** machine learning con redes neuronales grandes (más datos, más cómputo, patrones más complejos)
- **IA generativa:** modelos tan grandes que ya no solo clasifican o predicen un número: **generan**



Capa 1 • Data science

Es lo que siempre hicimos: mirar datos, limpiarlos, graficarlos, sacar conclusiones.

Una curva de declinación ajustada a mano ya es un modelo. Y la línea de tendencia sobre un Excel de costos o de demanda, también: la fórmula la pusiste vos, y los datos pusieron los parámetros. La estadística de la facultad vive acá.



Ajustala vos

`mpodelev.github.io/curso-ia-
energia` · día 1

Dos perillas y un número que tiene que bajar: el error. Bajalo todo lo que puedas.

Si ya lo hiciste antes de hoy, apretá "Reiniciar ejercicio" y arrancá de cero.



Capa 2 · Machine learning

Invierte la lógica: en vez de escribir la fórmula, **mostrás ejemplos y la máquina encuentra el patrón.**

Sirve cuando la fórmula no existe, o existe pero no la conocemos.

Mantenimiento predictivo: nadie sabe escribir la ecuación de "esta bomba va a fallar en tres semanas", pero hay miles de bombas que fallaron y sus datos previos.

Tu correo hace esto hace veinte años: nadie escribió la regla de qué es spam. Vio ejemplos.



Ahora que la busque la máquina

El botón está abajo del gráfico. Nadie le dijo los valores: tiene los puntos y un criterio.



Capa 3 · Deep learning

Machine learning con **redes neuronales grandes**. Más datos y más cómputo, y a cambio patrones mucho más complejos.

Acá entran las imágenes sísmicas, los registros de pozo, el texto. Y la cara que desbloquea tu teléfono: datos donde la señal está distribuida y no se deja resumir en cinco variables.

La capa arranca en 1989 (**LeNet** leyendo números escritos a mano, video de un minuto) y explota en 2012 (**AlexNet**, el mismo mecanismo con placas gráficas). Los dos videos están en la página.



Capa 4 · IA generativa

Modelos tan grandes, entrenados con tanto texto, que en lugar de solo clasificar o predecir un número, **generan**: texto, código, imágenes.

Los modelos grandes de lenguaje (**LLM**) son el caso que nos ocupa el resto del curso.

¿Y por qué explotó ahora, y no en 2010?



Tres cosas, ninguna mágica

- **Datos:** todo el texto de internet, disponible y digitalizado
- **Cómputo:** las placas gráficas (GPU), que resultaron ser justo la máquina que estos modelos necesitaban
- **Una arquitectura que escala:** el **transformer**, 2017



No hubo un descubrimiento
mágico: hubo una **receta que
mejora al agrandarla**



Dónde está esto en el software que ya usan

Machine learning lleva años escondido en herramientas de la industria: simuladores, interpretación sísmica, mantenimiento predictivo, control de procesos.

Lo nuevo desde fines de 2022 no es la IA. Es que **una parte de la IA se volvió conversacional**, y por eso llegó a todos los escritorios de golpe.



Demos en vivo

BLOQUE 3 DE 9 · 30 MIN



Tres tareas reales

- Resumir un **paper** de la **Society of Petroleum Engineers (SPE)**
- Explicar un **término técnico** a alguien no técnico
- Redactar un **correo difícil**

Y una cuarta, la más importante: **verlo fallar**.



Vamos al chatbot

Miren tres cosas: qué tan rápido responde, qué tan seguro suena, y si lo que dice es **verdad**.



Qué acabamos de ver

Rápido, ordenado, con buen tono. Y **sin ninguna garantía de que sea cierto.**

El chatbot no tiene un botón de "no sé". Cuando no sabe, sigue escribiendo igual.



Ahora, a hacerlo fallar



La salida de un LLM es un
borrador plausible, no una
fuente



¿Cuánto confiarías ahora?



Encuesta de relevamiento

BLOQUE 4 DE 9 · 12 MIN



La encuesta que ajusta el curso

El caso real del día 4 ya está armado sobre datos públicos. Lo que falta saber es lo de ustedes: qué rol tiene cada uno, qué tareas repetitivas le comen la semana, qué datos maneja y en qué formato.

El último bloque pide una sola cosa: **el problema que probarías primero**. Con eso arranca el taller del día 3, donde cada empresa escribe su caso en una página.



La encuesta está en la página del día 1

mpodeley.github.io/curso-ia-energia

Son doce preguntas y unos diez minutos. Sin datos confidenciales.



Discusión

BLOQUE 5 DE 9 · **15 MIN**



¿Qué tarea de tu semana laboral te parece más automatizable con lo que viste hoy?

¿Y cuál **menos**?



El chatbot respondió algo incorrecto con total seguridad

¿Le faltaba el dato, o el dato **no existía** y lo completó igual?



Pausa · 10 min

Volvemos a la 1:57 del cronómetro. Si te quedó la encuesta a medias, es el momento.



Tokens y predicción

BLOQUE 6 DE 9 · 40 MIN



El modelo no lee palabras: lee tokens

Antes de procesar nada, parte el texto en pedazos. Pueden ser palabras enteras, sílabas o letras sueltas.

Lo frecuente en internet entra como un solo token. Lo técnico, y casi todo el español, se parte en varios.



Antes de mirar: adiviná

¿En cuántos tokens parte el modelo la frase
perforación direccional?



Ahora abrilo: laboratorio de tokens

Está en la página del día 1. Empezá por **perforación direccional**.



Tres consecuencias que ya vieron sin saberlo

- **Cuenta mal las letras** de una palabra, porque nunca ve letras: ve pedazos
- **El español rinde menos:** la misma frase cuesta más tokens que en inglés
- **El uso por programa se cobra por token**, así que trabajar en español sale más caro



Una sola operación, repetida

Un **modelo grande de lenguaje** (LLM) hace una sola cosa.

Dado el texto hasta acá, le pone una probabilidad a cada token que podría seguir, elige uno, y vuelve a empezar. **No hay una base de datos de respuestas:** hay una máquina de continuar texto.



Elegí vos el próximo token

El segundo laboratorio de la página. Movele a la temperatura y mirá qué cambia.



El mismo mecanismo, con un modelo real adentro

poloclub.github.io/transformer-explainer

GPT-2 corriendo en el navegador: tokens, atención y la probabilidad de cada candidato, en vivo.



La temperatura elige entre candidatos, no inventa candidatos

Temperatura baja: gana casi siempre el más probable. Salida estable y repetitiva.

Temperatura alta: los poco probables tienen su oportunidad. Salida variada, a veces brillante y a veces disparatada.



¿En cuál de tus tareas querías
la versión aburrida?



Contexto y entrenamiento

BLOQUE 7 DE 9 · 25 MIN



La ventana de contexto es la memoria de trabajo

Todo lo que el modelo puede mirar para elegir el próximo token: tu pregunta, sus respuestas anteriores, los documentos que pegaste.

Tiene un tamaño máximo, medido en tokens. Lo que queda afuera, **no existe** para el modelo.



Achicá la ventana

`mpodelev.github.io/curso-ia-
energia` · día 1

Baja el tamaño de la ventana y mirá cuál es el mensaje que se cae primero.



De ahí salen dos frustraciones conocidas

En una conversación larga, el principio se cae del escritorio. El modelo no avisa: sigue contestando con lo que le queda.

Y en un documento grande, lo que se cayó tampoco se busca solo. Hay que volver a pegarlo.



Qué hacer con esto un martes a la mañana

- **Conversación nueva por tarea:** lo viejo no ayuda, ocupa lugar
- **Repetí la regla** cada tanto en una conversación larga: no es énfasis, es volver a ponerla en la ventana
- **Pegá el material**, no confíes en que lo recuerda



Cómo se entrena: dos etapas de tamaños muy distintos

Primero **lee** una fracción enorme de todo el texto humano, practicando una sola cosa: predecir lo que sigue. De ahí salen la gramática, los hechos y los patrones.

Después, una etapa **mucho más chica**: personas le enseñan a comportarse como asistente. El tono servicial y seguro sale de acá, y no tiene relación con si lo que dice es cierto.



Nadie escribió esas reglas: **se
ajustaron solas** mirando
ejemplos



Pausa · 10 min

Volvemos a la 3:12 del cronómetro. Dejá el chatbot abierto: lo usás al volver.



Alucinaciones en vivo

BLOQUE 8 DE 9 · 35 MIN



Si solo continúa texto plausible, cuando no sabe no se calla

No tiene un mecanismo para detectarse. Genera la continuación más plausible igual.

Un número de norma que parece real, un paper que suena citable, una cifra de producción con tres decimales.



Una palabra: ¿qué te preocupa
de que alucine?



Hagámoslo alucinar

Miren dos cosas: qué **seguro** suena, y cuánto tardamos en **verificarlo**.



Ahora vos: hacelo alucinar

Preguntale algo de **tu especialidad** que puedas verificar de memoria y sea público: una norma, una cifra del regulador, un nombre. Nada de tu empresa. Pegá la respuesta en el chat.



La salida de un LLM es un
borrador plausible, no una
fuente



Esto no se arregla con más cómputo

La ventana de contexto crece, los modelos mejoran, la frecuencia baja.
El mecanismo no cambia.

Lo que sí se puede cambiar es **de dónde saca el material**, y eso es el día 3.



Cierre

BLOQUE 9 DE 9 · 13 MIN



Las cuatro maneras de fallar

- **Inventa lo que no sabe:** de cómo genera el texto, token por token
· hoy
- **No hace lo que le pediste:** de cuánto control dan las instrucciones
· mañana
- **Está seguro y equivocado:** de lo que aprendió y de lo que no · día 3
- **Se olvida de lo que le dijiste:** de cuánto puede mirar a la vez · hoy y día 3



Qué hacer con esto desde mañana

- **Tareas donde podés verificar rápido:** ahí rinde y el riesgo es bajo
- **Poné el material en la ventana:** pegá el texto en vez de confiar en su memoria
- **Desconfiá de todo número, cita o norma** que no hayas visto con tus ojos



Tarea para mañana

Traé **una tarea real de tu semana** que le pedirías a un chatbot.

Tres líneas: qué le pedirías, qué material tendrías que darle, y cómo sabrías si lo hizo bien.

Si ya tenés cuenta, probala (sin datos confidenciales) y anotá qué salió **mal**. Cinco minutos.



Mañana: prompting y análisis asistido de datos

- Escribir prompts con **rol, contexto, tarea, formato y ejemplos**, sobre tu tarea
- Saber **qué información de la empresa no debe subirse** a un chatbot
- Del **reporte diario de la ARCH** a una tabla verificada, y una declinación sobre pozos reales



Nos vemos mañana

EL QUIZ, LOS RECURSOS Y LOS LABORATORIOS QUEDAN EN LA PÁGINA .
[MPODELEY.GITHUB.IO/CURSO-IA-ENERGIA](https://mpondeley.github.io/curso-ia-energia)