

Cómo funciona un LLM

SESIÓN 2 DE 8 · DÍA 1 · 2 H EN VIVO · PCR · CGC · TECPETROL · ANDES PETROLEUM

Tokens y predicción

BLOQUE 1 DE 4 · **38 MIN**



Esta sesión

BLOQUE	TIEMPO	QUÉ HACEMOS
Tokens y predicción	38 min	Los dos primeros laboratorios de la página, y un modelo real abierto en el navegador
Contexto y entrenamiento	25 min	La ventana de contexto en vivo con el tercer laboratorio, y cómo se entrena en dos etapas
Pausa	10 min	Dejá el chatbot abierto: lo usás al volver
Alucinaciones en vivo	35 min	Lo hacemos alucinar: primero el instructor, después cada uno con una pregunta de su especialidad
Cierre: las cuatro maneras de fallar, takeaways, tarea	12 min	La hoja de ruta del curso, tres prácticas para mañana y la tarea de cinco minutos



Al final de esta sesión van a poder

- Entender qué es un **token**, cómo el modelo predice el siguiente y qué controla la temperatura
- Ver qué entra en la **ventana de contexto**, qué se cae, y cómo se entrena el modelo
- Derivar de esa mecánica **por qué alucina**



El modelo no lee palabras: lee tokens

Antes de procesar nada, parte el texto en pedazos. Pueden ser palabras enteras, sílabas o letras sueltas.

Lo frecuente en internet entra como un solo token. Lo técnico, y casi todo el español, se parte en varios.



Antes de mirar: adiviná

¿En cuántos tokens parte el modelo la frase
perforación direccional?



Ahora abrilo: laboratorio de tokens

Está en la página de la sesión 2. Empezá por **perforación direccional**.



Tres consecuencias que ya vieron sin saberlo

- **Cuenta mal las letras** de una palabra, porque nunca ve letras: ve pedazos
- **El español rinde menos:** la misma frase cuesta más tokens que en inglés
- **El uso por programa se cobra por token**, así que trabajar en español sale más caro



Una sola operación, repetida

Un **modelo grande de lenguaje** (LLM) hace una sola cosa.

Dado el texto hasta acá, le pone una probabilidad a cada token que podría seguir, elige uno, y vuelve a empezar. **No hay una base de datos de respuestas:** hay una máquina de continuar texto.



Elegí vos el próximo token

El segundo laboratorio de la página. Movele a la temperatura y mirá qué cambia.



El mismo mecanismo, con un modelo real adentro

poloclub.github.io/transformer-explainer

GPT-2 corriendo en el navegador: tokens, atención y la probabilidad de cada candidato, en vivo.



La temperatura elige entre candidatos, no inventa candidatos

Temperatura baja: gana casi siempre el más probable. Salida estable y repetitiva.

Temperatura alta: los poco probables tienen su oportunidad. Salida variada, a veces brillante y a veces disparatada.



¿En cuál de tus tareas querías
la versión aburrida?



Contexto y entrenamiento

BLOQUE 2 DE 4 · **25 MIN**



La ventana de contexto es la memoria de trabajo

Todo lo que el modelo puede mirar para elegir el próximo token: tu pregunta, sus respuestas anteriores, los documentos que pegaste.

Tiene un tamaño máximo, medido en tokens. Lo que queda afuera, **no existe** para el modelo.



Achicá la ventana

`mpodelev.github.io/curso-ia-
energia` · sesión 2

Baja el tamaño de la ventana y mirá cuál es el mensaje que se cae primero.



De ahí salen dos frustraciones conocidas

En una conversación larga, el principio se cae del escritorio. El modelo no avisa: sigue contestando con lo que le queda.

Y en un documento grande, lo que se cayó tampoco se busca solo. Hay que volver a pegarlo.



Qué hacer con esto un martes a la mañana

- **Conversación nueva por tarea:** lo viejo no ayuda, ocupa lugar
- **Repetí la regla** cada tanto en una conversación larga: no es énfasis, es volver a ponerla en la ventana
- **Pegá el material,** no confíes en que lo recuerda



Cómo se entrena: dos etapas de tamaños muy distintos

Primero **lee** una fracción enorme de todo el texto humano, practicando una sola cosa: predecir lo que sigue. De ahí salen la gramática, los hechos y los patrones.

Después, una etapa **mucho más chica**: personas le enseñan a comportarse como asistente. El tono servicial y seguro sale de acá, y no tiene relación con si lo que dice es cierto.



Nadie escribió esas reglas: **se
ajustaron solas** mirando
ejemplos



Pausa · 10 min

Volvemos a la 1:13 del cronómetro. Dejá el chatbot abierto: lo usás al volver.



Alucinaciones en vivo

BLOQUE 3 DE 4 · **35 MIN**



Si solo continúa texto plausible, cuando no sabe no se calla

No tiene un mecanismo para detectarse. Genera la continuación más plausible igual.

Un número de norma que parece real, un paper que suena citable, una cifra de producción con tres decimales.



Una palabra: ¿qué te preocupa
de que alucine?



Hagámoslo alucinar

Miren dos cosas: qué **seguro** suena, y cuánto tardamos en **verificarlo**.



Ahora vos: hacelo alucinar

Preguntale algo de **tu especialidad** que puedas verificar de memoria y sea público: una norma, una cifra del regulador, un nombre. Nada de tu empresa. Pegá la respuesta en el chat.



La salida de un LLM es un
borrador plausible, no una
fuente



Esto no se arregla con más cómputo

La ventana de contexto crece, los modelos mejoran, la frecuencia baja.
El mecanismo no cambia.

Lo que sí se puede cambiar es **de dónde saca el material**, y eso es la sesión 5.



Cierre

BLOQUE 4 DE 4 · **12 MIN**



Las cuatro maneras de fallar

- **Inventa lo que no sabe:** de cómo genera el texto, token por token
· hoy
- **No hace lo que le pediste:** de cuánto control dan las instrucciones
· mañana
- **Está seguro y equivocado:** de lo que aprendió y de lo que no ·
sesión 5
- **Se olvida de lo que le dijiste:** de cuánto puede mirar a la vez · hoy
y sesión 5



Qué hacer con esto desde mañana

- **Tareas donde podés verificar rápido:** ahí rinde y el riesgo es bajo
- **Poné el material en la ventana:** pegá el texto en vez de confiar en su memoria
- **Desconfiá de todo número, cita o norma** que no hayas visto con tus ojos



Tarea para mañana

Traé **una tarea real de tu semana** que le pedirías a un chatbot.

Tres líneas: qué le pedirías, qué material tendrías que darle, y cómo sabrías si lo hizo bien.

Si ya tenés cuenta, probala (sin datos confidenciales) y anotá qué salió **mal**. Cinco minutos.



Mañana, sesiones 3 y 4: prompting y análisis asistido de datos

- Escribir prompts con **rol, contexto, tarea, formato y ejemplos**, sobre tu tarea
- Saber **qué información de la empresa no debe subirse** a un chatbot
- Del **reporte diario de la ARCH** a una tabla verificada, y una declinación sobre pozos reales



Nos vemos mañana

EL QUIZ, LOS RECURSOS Y LOS LABORATORIOS QUEDAN EN LA PÁGINA .
[MPODELEY.GITHUB.IO/CURSO-IA-ENERGIA](https://mpondeley.github.io/curso-ia-energia)