

# Cómo funciona un LLM

---

SESIÓN 2 DE 8 · 2 H EN VIVO · YPFB ANDINA

# Hoy

| BLOQUE                      | TIEMPO | QUÉ HACEMOS                                                    |
|-----------------------------|--------|----------------------------------------------------------------|
| Apertura y entrada al sitio | 8 min  | Objetivos y el PIN, como la semana pasada                      |
| Repaso de la tarea          | 15 min | Qué les salió bien y mal con el chatbot esta semana            |
| Tokens y predicción         | 33 min | Recorremos juntos los dos primeros ejercicios de la página     |
| Contexto y entrenamiento    | 20 min | La memoria de trabajo en vivo, y cómo se entrena en dos etapas |
| Alucinaciones en vivo       | 30 min | Lo hacemos alucinar: primero el instructor, después cada uno   |
| Cierre y tarea              | 14 min | Dos de las cuatro maneras de fallar, y qué hacer con esto      |



# Al final de esta sesión van a poder

- Entender qué es un **token** y por qué importa para todo lo demás
- Ver que el modelo **predice el próximo token**, y qué controla la temperatura
- Derivar de esa mecánica **por qué los modelos alucinan**

Hoy levantamos el capó un rato: mecánica, solo la que sirve para manejar mejor.



# Entrá al sitio, como la semana pasada

[mpodeley.github.io/curso-energia-ypfb](https://mpodeley.github.io/curso-energia-ypfb)

Hoy usamos la página de la sesión 2. El PIN es el mismo y el navegador ya se acuerda.



# Repaso de la tarea

BLOQUE 1 DE 5 · **15 MIN**



# ¿Qué le pidieron al chatbot esta semana?



# ¿Y qué salió mal?



# Nada de eso fue un error del programa

Las tres fallas más comunes tienen la misma raíz, y la vamos a ver funcionar hoy.

Las próximas dos horas son esa explicación.



# Tokens y predicción

BLOQUE 2 DE 5 · **33 MIN**



# El modelo no lee palabras: lee tokens

Antes de procesar nada, parte el texto en pedazos. Pueden ser palabras enteras, sílabas o letras sueltas.

Lo frecuente en internet entra como un solo token. Lo técnico, y casi todo el español, se parte en varios.



# Antes de mirar: adiviná

¿En cuántos tokens parte el modelo la frase  
**perforación direccional?**



# Ahora abrilo: laboratorio de tokens

Está en la página de la sesión 2. Empezá por **perforación direccional**.



# Tres consecuencias que ya vieron sin saberlo

- **Cuenta mal las letras** de una palabra, porque nunca ve letras: ve pedazos
- **El español rinde menos:** la misma frase cuesta más tokens que en inglés
- **Las interfaces cobran por token**, así que trabajar en español sale más caro



# Una sola operación, repetida

Un **modelo grande de lenguaje** (LLM) hace una sola cosa.

Dado el texto hasta acá, le pone una probabilidad a cada token que podría seguir, elige uno, y vuelve a empezar. **No hay una base de datos de respuestas:** hay una máquina de continuar texto.



# Elegí vos el próximo token

El segundo ejercicio de la página. Movele a la temperatura y mirá qué cambia.



# La temperatura elige entre candidatos, no inventa candidatos

Temperatura baja: gana casi siempre el más probable. Salida estable y repetitiva.

Temperatura alta: los poco probables tienen su oportunidad. Salida variada, a veces brillante y a veces disparatada.



¿En cuál de tus tareas querías  
la versión aburrida?



# Contexto y entrenamiento

BLOQUE 3 DE 5 · **20 MIN**



# La ventana de contexto es la memoria de trabajo

Todo lo que el modelo puede mirar para elegir el próximo token: tu pregunta, sus respuestas anteriores, los documentos que pegaste.

Tiene un tamaño máximo, medido en tokens. Lo que queda afuera, **no existe** para el modelo.



# Achicá la ventana

`mpodeley.github.io/curso-energia-ypfb` · sesión 2

Baja el tamaño de la ventana y mirá cuál es el mensaje que se cae primero.



# De ahí salen dos frustraciones conocidas

En una conversación larga, el principio se cae del escritorio. El modelo no avisa: sigue contestando con lo que le queda.

Y en un documento grande, lo que se cayó tampoco se busca solo. Hay que volver a pegarlo.



# Cómo se entrena: dos etapas de tamaños muy distintos

Primero **lee** una fracción enorme de todo el texto humano, practicando una sola cosa:

predecir lo que sigue. De ahí salen la gramática, los hechos y los patrones.

Después, una etapa **mucho más chica**: personas le enseñan a comportarse como asistente.

El tono servicial y seguro sale de acá, y no tiene relación con si lo que dice es cierto.



Nadie escribió esas reglas: **se  
ajustaron solas** mirando  
ejemplos



# Alucinaciones en vivo

BLOQUE 4 DE 5 · **30 MIN**



# Si solo continúa texto plausible, cuando no sabe no se calla

No tiene un mecanismo para detectarse. Genera la continuación más plausible igual.

Un número de norma que parece real, un paper que suena citable, una cifra de producción con tres decimales.



Una palabra: ¿qué te preocupa  
de que alucine?



# Hagámoslo alucinar

Miren dos cosas: qué **seguro** suena, y cuánto tardamos en **verificarlo**.



# Ahora vos: hacelo alucinar

Preguntale algo de **tu especialidad** que puedas verificar de memoria: una cifra, una norma, un nombre. Pegá la respuesta en el chat de la videollamada.



La salida de un LLM es un  
**borrador plausible**, no una  
fuente



# Esto no se arregla con más cómputo

La ventana de contexto crece, los modelos mejoran, la frecuencia baja.  
El mecanismo no cambia.

Lo que sí se puede cambiar es **de dónde saca el material**, y eso es la sesión 5.



# Cierre y tarea

BLOQUE 5 DE 5 · **14 MIN**



# Dos de las cuatro, y las dos por diseño

- **Inventa lo que no sabe:** de la predicción del próximo token, que vieron hoy
- **Se olvida de lo que le dijiste:** de la ventana de contexto, que también vieron hoy
- **Está seguro y equivocado:** sesión 5
- **No hace lo que le pediste:** sesión 3



# Qué hacer con esto el lunes

- **Tareas donde podés verificar rápido:** ahí rinde y el riesgo es bajo
- **Poné el material en la ventana:** pegá el texto en vez de confiar en su memoria
- **Desconfiá de todo número, cita o norma** que no hayas visto con tus ojos



# Tarea para la sesión 3

Traé anotadas **tres tareas repetitivas de tu semana** que involucren texto, planillas o documentos.

No hace falta que las resuelvas. Solo anotalas. En la sesión 3 las convertimos en prompts.



# La sesión 3: prompting y trabajo diario

- Escribir prompts con **rol, contexto, tarea, formato y ejemplos**
- Aplicarlo a informes, resúmenes, minutas y traducción técnica
- Saber **qué información de la empresa no debe subirse** a un chatbot



# Nos vemos en la sesión 3

---

EL QUIZ Y LOS TRES EJERCICIOS QUEDAN EN LA PÁGINA • [MPODELEY.GITHUB.IO/CURSO-ENERGIA-YPFB](https://mpondeley.github.io/curso-energia-ypfb)