

Cómo funciona un LLM

SESIÓN 2 DE 8 · 2 H EN VIVO · YPFB ANDINA

Hoy

BLOQUE	TIEMPO	QUÉ HACEMOS
Repaso de la tarea	15 min	Qué les salió bien y mal con el chatbot esta semana
Tokens y predicción	35 min	Recorremos juntos los dos ejercicios de la página
Contexto y entrenamiento	30 min	La memoria de trabajo del modelo, y cómo se entrena
Alucinaciones en vivo	25 min	Lo hacemos alucinar y analizamos por qué pasa
Cierre y tarea	15 min	Qué significa esto para usarlo bien



Al final de esta sesión van a poder

- Entender qué es un **token** y por qué importa para todo lo demás
- Ver que el modelo **predice el próximo token**, y qué controla la temperatura
- Derivar de esa mecánica **por qué los modelos alucinan**



Entrá al sitio, como la semana pasada

podeley.github.io/curso-energia-ypfb

Hoy usamos la página de la sesión 2. El PIN es el mismo y el navegador ya se acuerda.



Repaso de la tarea

BLOQUE 1 DE 5 · **15 MIN**



¿Qué le pidieron al chatbot esta semana?



¿Y qué salió mal?



Nada de eso fue un error del programa

Las tres fallas más comunes tienen la misma raíz, y la vamos a ver funcionar hoy.

Las próximas dos horas son esa explicación.



Tokens y predicción

BLOQUE 2 DE 5 · **35 MIN**



El modelo no lee palabras: lee tokens

Antes de procesar nada, parte el texto en pedazos. Pueden ser palabras enteras, sílabas o letras sueltas.

Lo frecuente en internet entra como un solo token. Lo técnico, y casi todo el español, se parte en varios.



Antes de mirar: adiviná

¿En cuántos tokens parte el modelo la frase
perforación direccional?



Ahora abrilo: laboratorio de tokens

Está en la página de la sesión 2. Empezá por **perforación direccional**.



Tres consecuencias que ya vieron sin saberlo

- **Cuenta mal las letras** de una palabra, porque nunca ve letras: ve pedazos
- **El español rinde menos:** la misma frase cuesta más tokens que en inglés
- **Las interfaces cobran por token**, así que trabajar en español sale más caro



Una sola operación, repetida

Un **modelo grande de lenguaje** (LLM) hace una sola cosa.

Dado el texto hasta acá, le pone una probabilidad a cada token que podría seguir, elige uno, y vuelve a empezar. **No hay una base de datos de respuestas:** hay una máquina de continuar texto.



Elegí vos el próximo token

El segundo ejercicio de la página. Movele a la temperatura y mirá qué cambia.



La temperatura elige entre candidatos, no inventa candidatos

Temperatura baja: gana casi siempre el más probable. Salida estable y repetitiva.

Temperatura alta: los poco probables tienen su oportunidad. Salida variada, a veces brillante y a veces disparatada.



¿En cuál de tus tareas querías
la versión aburrida?



Contexto y entrenamiento

BLOQUE 3 DE 5 · **30 MIN**



La ventana de contexto es la memoria de trabajo

Todo lo que el modelo puede mirar para elegir el próximo token: tu pregunta, sus respuestas anteriores, los documentos que pegaste.

Tiene un tamaño máximo, medido en tokens. Lo que queda afuera, **no existe** para el modelo.



De ahí salen dos frustraciones conocidas

En una conversación larga, el principio se cae del escritorio. El modelo no avisa: sigue contestando con lo que le queda.

Y en un documento grande, lo que se cayó tampoco se busca solo. Hay que volver a pegarlo.



Primera etapa: leer

El modelo lee una fracción enorme de todo el texto humano y practica una sola cosa: predecir lo que sigue.

De ahí salen la gramática, los hechos y los patrones de razonamiento. Nadie los escribió como reglas: se ajustaron solos.



Segunda etapa: aprender a conversar

Un modelo que solo continúa texto no responde preguntas: las continúa. Después de esa primera etapa hay una segunda, mucho más chica, donde personas le enseñan a comportarse como asistente.

Ahí aprende a responder, a seguir instrucciones y a negarse a algunas cosas.



Nadie escribió esas reglas: **se
ajustaron solas** mirando
ejemplos



Se puede mirar adentro, con esfuerzo

En 1989, en los laboratorios Bell, Yann LeCun mostró una red que leía números escritos a mano.

El video dura un minuto y está en la página.

Esa red no aprende "el número 7". Aprende a **descomponer la imagen en piezas**: primero bordes, después curvas, después partes reconocibles.



Alucinaciones en vivo

BLOQUE 4 DE 5 · **25 MIN**



Si solo continúa texto plausible, cuando no sabe no se calla

No tiene un mecanismo para detectarse. Genera la continuación más plausible igual.

Un número de norma que parece real, un paper que suena citable, una cifra de producción con tres decimales.



Una palabra: ¿qué te preocupa
de que alucine?



Hagámoslo alucinar

Miren dos cosas: qué **seguro** suena, y cuánto tardamos en **verificarlo**.



La salida de un LLM es un
borrador plausible, no una
fuente



Esto no se arregla con más cómputo

La ventana de contexto crece, los modelos mejoran, la frecuencia baja.
El mecanismo no cambia.

Lo que sí se puede cambiar es **de dónde saca el material**, y eso es la sesión 5.



Cierre y tarea

BLOQUE 5 DE 5 · **15 MIN**



Qué hacer con esto el lunes

- **Tareas donde podés verificar rápido:** ahí rinde y el riesgo es bajo
- **Poné el material en la ventana:** pegá el texto en vez de confiar en su memoria
- **Desconfiá de todo número, cita o norma** que no hayas visto con tus ojos



Tarea para la sesión 3

Traé anotadas **tres tareas repetitivas de tu semana** que involucren texto, planillas o documentos.

No hace falta que las resuelvas. Solo anotalas. En la sesión 3 las convertimos en prompts.



La sesión 3: prompting y trabajo diario

- Escribir prompts con **rol, contexto, tarea, formato y ejemplos**
- Aplicarlo a informes, resúmenes, minutas y traducción técnica
- Saber **qué información de la empresa no debe subirse** a un chatbot



Nos vemos en la sesión 3

EL QUIZ Y LOS DOS EJERCICIOS QUEDAN EN LA PÁGINA • [PODELEY.GITHUB.IO/CURSO-ENERGIA-YPFB](https://podeley.github.io/curso-energia-ypfb)