

Riesgos, límites y gobernanza

SESIÓN 7 DE 8 · DÍA 4: RIESGOS Y EL CASO REAL · 2 H EN VIVO · PCR · CGC ·
TECPETROL · ANDES PETROLEUM

Apertura

BLOQUE 1 DE 6 · **8 MIN**



Esta sesión

BLOQUE	TIEMPO	QUÉ HACEMOS
Apertura	8 min	Las ventanas del día y el caso de cada uno a mano
La cacería	20 min	Inversiones cazadas en vivo, cada una con su causa
El protocolo	25 min	Cuánto verificar según el costo del error
Datos de la empresa	20 min	Datos reales en los tres niveles, y el borde entre cuatro empresas
Agentes y operación	20 min	Donde el error no es reversible, el loop no sirve
La política	17 min	El borrador de una página, redactado en vivo, y tres prácticas para llevarse
Pausa	10 min	A las 12:00 (10:00 en Ecuador y Colombia) sigue la sesión 8



Al final de esta sesión van a poder

- Ponerle **causa** a un error concreto, con la tabla de las cuatro propiedades
- Dosificar la verificación según el **costo del error**, y ubicar cada dato en su nivel
- Salir con el **borrador de política** de una página para su empresa



Entrá al sitio, como siempre

[**mpodeley.github.io/curso-ia-energia**](https://mpodeley.github.io/curso-ia-energia)

Hoy usamos la página de la sesión 7. Tené a mano **tu caso en una página**: en la sesión 8 pasa por el protocolo. El bloque que sigue se juega en el ejercicio de la **cacería de alucinaciones**.



La cacería

BLOQUE 2 DE 6 · **20 MIN**



A cazar invenciones

Abrí la **cacería de alucinaciones**: tres informes con errores plantados. Cinco minutos en el primero, marcando lo que **no sale de los datos**. Después, ronda.



Cuatro propiedades, cuatro arreglos

- **Predice el próximo token:** el dato lo traés vos, él lo redacta
- **Conocimiento:** adjuntale el documento para que lo lea
- **Memoria de trabajo:** conversaciones cortas, y repetí lo que no puede perderse
- **Control de la salida:** describí mejor el resultado, o mostrale un ejemplo



El protocolo

BLOQUE 3 DE 6 · **25 MIN**



Lo verificable y lo inventado

Lo verificable es lo que **se deriva de lo que le diste**. Lo inventado es lo que tuvo que completar.

Un resumen de tu planilla suele estar bien. Una causa, una cita, un artículo de una norma, casi nunca.



Esto ya pasó: Deloitte, octubre de 2025

Un informe de AU\$ 440,000 para el gobierno australiano salió con **citas académicas inventadas** y una cita judicial falsa.

La firma devolvió parte de los honorarios.



El protocolo, por costo del error

- **Borrador que vas a reescribir:** se reescribe sin verificar
- **Texto con tu nombre:** todo dato puntual, contra la fuente
- **Cifra en informe firmado:** fuente primaria a la vista, sin excepción
- **Normativa:** siempre con el texto de la norma adjunto



Si no podés abrir la fuente en
dos minutos, el número no entra



Datos de la empresa

BLOQUE 4 DE 6 · **20 MIN**



El mapa de tres niveles

- **Nunca, en ninguna herramienta externa:** producción real por pozo, reservas, contratos, personas
- **Solo en herramientas contratadas,** con acuerdo de datos: documentos internos no críticos
- **En cualquiera, incluso gratuita:** lo público, lo ya publicado, lo sintético



Cuatro empresas en una sala: el chat compartido es **una herramienta externa** para las otras tres



Clasifiquemos datos de verdad

Ronda: **la categoría** de un dato con el que trabajás todas las semanas. La sala lo pone en su nivel.

Nos detenemos en **los casos de borde**.



El truco del tercer nivel

Para probar un análisis o afinar un prompt, una **planilla sintética** con las mismas columnas funciona igual de bien que la real.



Agentes y operación

BLOQUE 5 DE 6 · **20 MIN**



El loop supone que equivocarse es barato

Ayer: el error vuelve y se corrige. Funciona porque leer y calcular son **reversibles**.

En un sistema que opera equipos, un paso equivocado termina en una **válvula en la posición que no era**.



La regla de dos

La regla de dos: de estos tres poderes, como mucho dos



Las tres combinaciones

✓ A + C, sin B

Scraping de datos públicos,
sin acceso a nada interno

✓ B + C, sin A

Partes internos a una base,
con archivos de fuente conocida

✓ A + B, sin C

Lee todo, pero solo propone;
una persona ejecuta

✗ Las tres juntas

Solo con una persona que
aprueba cada acción

Esto ya pasó: EchoLeak y postmark-mcp, 2025

Un correo, sin clic: Microsoft 365 Copilot seguía instrucciones escondidas en un mail y sacaba datos de su alcance. Microsoft lo corrigió en sus servidores.

Un conector: un servidor MCP para mandar correos empezó a copiar cada mensaje a un tercero.



Esto ya pasó: Replit, julio de 2025

Un agente de programación **borró la base de datos de producción** de una empresa, en pleno congelamiento de cambios.

Después informó que la recuperación era imposible, y se equivocó: se pudo recuperar.



Cuánto dejarlo hacer solo

La escalera de autonomía



Para empezar en una empresa: escalones 2 y 3. El 5 no se usa con datos ni sistemas de la empresa.



Las cuatro tareas, con su control

TAREA	EL CONTROL QUE NO SE NEGOCIA
Bajar datos públicos	El agente que navega no ve nada interno
Partes internos a una base	Staging, sin permiso de borrar, y una persona antes de producción
Modelos de simulación	Copia del deck, diff contra el caso base, firma del ingeniero
Tableros de monitoreo	Solo lectura sobre una réplica; el agente no entra a la red de operación

El detalle, en **la guía de agentes**.



Sin garantías de comportamiento

De un modelo se puede observar que hasta ahora no hizo algo, pero no se puede **demostrar** que nunca lo va a hacer.

La seguridad industrial se diseña al revés: garantías demostrables, modos de falla conocidos.



Entre el modelo y el campo, **una
persona con nombre y apellido**



La política

BLOQUE 6 DE 6 · **17 MIN**



Quién responde ya tiene respuesta

Air Canada, 2024: su chatbot **inventó una política de descuentos** y un tribunal obligó a la aerolínea a cumplirla.

Para el tribunal, lo que dijo el chatbot lo dijo la empresa.



La política, en una página

La redactamos en vivo sobre un borrador editable de
seis puntos: herramientas aprobadas, mapa de
datos, verificación, declaración de asistencia, a quién
consultar, y agentes.



Para llevarse

- Frente a un error, **buscale la causa** (dato, documento, memoria o formato) antes de reescribir el prompt
- **Verificá según el costo del error:** si no podés abrir la fuente en dos minutos, el número no entra
- Antes de pegar un dato, **ubicalo en su nivel**; ante la duda, el más alto



Pausa · 10 min

A LAS **12:00** (10:00 EN ECUADOR Y COLOMBIA) SIGUE LA **SESIÓN 8**, CON SU PROPIO DECK:
EL CASO Y EL HORIZONTE

