

Información, riesgos y política de uso

SESIÓN 7 DE 8 · DÍA 4: RIESGOS Y EL CASO REAL · 2 H EN VIVO · PCR · CGC ·
TECPETROL · ANDES PETROLEUM

Apertura

BLOQUE 1 DE 7 · **5 MIN**



Esta sesión

BLOQUE	TIEMPO	QUÉ HACEMOS
Apertura	5 min	Para qué se habla de riesgos: para habilitar el uso
Información y relevamiento	20 min	El mapa de tres niveles, y la ronda de qué se usa hoy
Cuando se equivoca o miente	20 min	Verificar según el costo del error, y el plan B
Agentes, entorno aislado y correo	25 min	Dónde corre un agente, qué puede tocar, y por qué no entra a la casilla
Enjambres y Hugging Face	15 min	Muchos agentes a la vez, y el caso de julio con su video
Los atacantes también tienen IA	10 min	El segundo canal, y por qué el campo queda aparte
La política	15 min	El recorrido por el documento, y tres prácticas para llevarse
Pausa	10 min	A las 12:00 (10:00 en Ecuador y Colombia) sigue la sesión 8



Al final de esta sesión van a poder

- Ubicar cada dato en **su nivel**, y armar el relevamiento de lo que el equipo ya usa
- Dosificar la verificación según el **costo del error**, y tener un **plan B**
- Decidir **dónde corre un agente** y qué puede tocar
- Salir con la **política de uso** para su empresa



Hablamos de riesgos para poder
usarla más, no menos



Información y relevamiento

BLOQUE 2 DE 7 · 20 MIN



El mapa de tres niveles

- **Nivel 1, nunca en una herramienta externa:** producción real por pozo, reservas, contratos, personas
- **Nivel 2, solo en herramientas contratadas,** con acuerdo de datos: documentos internos no críticos
- **Nivel 3, en cualquiera, incluso gratuita:** lo público, lo ya publicado, lo sintético



El nivel del dato, y adónde va

Qué dato va a qué herramienta

	Nivel 1 producción, reservas, contratos	Nivel 2 documentos internos	Nivel 3 público o sintético
Cuenta personal o gratuita lo que subís puede usarse para entrenar	✗	✗	✓
Cuenta contratada por la empresa con acuerdo de datos y sin entrenamiento	✗	✓	✓
Agente en un entorno aislado trabaja sobre copias, con credencial propia	✗	✓	✓
Herramienta dentro de la red el dato no sale de la empresa	✓	✓	✓

Ante la duda, se asume el nivel más alto y se consulta.



Cuatro empresas en una sala: el chat compartido es **una herramienta externa** para las otras tres



El relevamiento

El relevamiento: una fila por herramienta

Herramienta	Quién la usa	Para qué	Cuenta	Datos	Conectores	¿Agente?
Chatbot gratuito	Ingeniería	Redactar correos	Personal	Nivel 3	Ninguno	No
Asistente de la suite	Todo el equipo	Resumir reuniones	Contratada	Nivel 2	Correo, agenda	No
Agente de terminal	Reservorios	Armar tableros	Contratada	Nivel 2, copia	Carpeta aislada	Sí
Extensión del navegador	Sin relevar	Sin relevar	Personal	Sin relevar	Lee cada página	Sí

La fila que falta es la que importa: lo que se usa y nadie anotó.

Aprobar
ya cumple: entra a la lista

Contratar
sirve, pero con cuenta de empresa

Reemplazar
hay una aprobada que hace lo mismo

Cada fila termina en una de tres decisiones. Se repite cada tres meses.

¿Qué se está usando hoy?

Ronda: **una herramienta de IA** que usás en el trabajo, con qué tipo de cuenta, y si tiene algún conector activo.

Sin datos propios: solo la herramienta y la cuenta.



Cuando se equivoca o miente

BLOQUE 3 DE 7 · **20 MIN**



Se equivoca: inventa con buena forma

Deloitte, octubre de 2025: un informe de AU\$ 440,000 para el gobierno australiano, con citas académicas inventadas. Devolvió parte de los honorarios.

Abogados: más de 2,000 fallos con citas inventadas, varios en Argentina.



Cuatro propiedades, cuatro arreglos

- **Predice el próximo token:** el dato lo traés vos, él lo redacta
- **Conocimiento:** adjuntale el documento para que lo lea
- **Memoria de trabajo:** conversaciones cortas, y repetí lo que no puede perderse
- **Control de la salida:** describí mejor el resultado, o mostrale un ejemplo



Miente: informa algo que no hizo

Replit, julio de 2025: un agente borró la base de producción, generó registros ficticios y afirmó que no se podía recuperar. Se pudo.

En laboratorio: frente a un conflicto armado a propósito, varios modelos eligieron engañar o presionar a una persona.



El protocolo, por costo del error

- **Borrador que vas a reescribir:** se reescribe sin verificar
- **Texto con tu nombre:** todo dato puntual, contra la fuente
- **Cifra en informe firmado:** fuente primaria a la vista. Si no se abre en dos minutos, no entra
- **Normativa:** siempre con el texto de la norma adjunto
- **Trabajo de un agente:** se revisa el resultado, no el resumen



Depender de más, y el plan B

Tres maneras de depender de más, y su plan B

EL RIESGO

La herramienta se cae

Una caída, un cambio de precio o de condiciones, y la tarea queda sin hacer.



Se pierde la habilidad

Lo que siempre hace el asistente, el equipo deja de saber hacerlo.



Se deja de revisar

Como casi siempre acierta, se aprueba sin leer. Y se siente más rápido de lo que es.



EL PLAN B

Procedimiento escrito para hacerla sin IA, y una segunda herramienta de otro proveedor.

Dos personas que saben hacer la tarea a mano, y la practican una vez por semestre.

Quien firma explica el resultado sin el asistente abierto. Si no puede, no sale.

Vale para las tareas críticas: las que tienen un plazo comprometido con alguien de afuera.

Tu tarea crítica

Ronda: **una tarea** que hoy hacés con IA y que tiene un plazo comprometido con alguien de afuera. Si mañana la herramienta no está, ¿quién la hace y cómo?



Agentes, entorno aislado y correo

BLOQUE 4 DE 7 · **25 MIN**



La regla de dos

La regla de dos: de estos tres poderes, como mucho dos



Las tres combinaciones

✓ A + C, sin B

Scraping de datos públicos,
sin acceso a nada interno

✓ B + C, sin A

Partes internos a una base,
con archivos de fuente conocida

✓ A + B, sin C

Lee todo, pero solo propone;
una persona ejecuta

✗ Las tres juntas

Solo con una persona que
aprueba cada acción

Dónde corre el agente

El mismo agente, en dos lugares

En tu máquina de trabajo

El agente

Lo que el agente alcanza

- Toda la unidad, no solo la carpeta
- El correo y el navegador abiertos
- Las credenciales guardadas
- La red de la empresa

Si se equivoca, se equivoca con tus permisos.

En un entorno aislado (sandbox)

El agente

Lo que el agente alcanza

- Una copia de los datos de la tarea
- Una credencial propia y acotada
- Ningún correo, ninguna contraseña
- Solo los sitios de una lista

Si se equivoca, se pierde una copia.

Un entorno aislado puede ser una carpeta dedicada, una máquina virtual o el entorno en la nube del proveedor.

Por defecto, el agente corre ahí. Lo otro se pide.

Esto ya pasó: PocketOS, abril de 2026

Un agente de programación encontró en un archivo **un token con más alcance del necesario** y borró el volumen de producción en segundos.

Las copias de respaldo estaban **en ese mismo volumen**.



Cuánto dejarlo hacer solo


La escalera de autonomía




Para empezar en una empresa: escalones 2 y 3. El 5 no se usa con datos ni sistemas de la empresa.

El correo es la llave maestra

El correo es la llave maestra



DÓNDE SE CORTA LA CADENA



Redactar, resumir y ordenar correo sigue habilitado, en modo borrador: el asistente propone y la persona envía.

Esto ya pasó: el asistente de soporte de Meta, 2026

Los atacantes le pedían que asociara **un correo nuevo** a una cuenta ajena de Instagram. El asistente mandaba el código ahí. Fueron **20,225 cuentas**.

Las que tenían segundo factor no se vieron afectadas.



El agente que querés armar

Pensá en el agente de **tu caso en una página**. Dos preguntas, en el chat:

¿Dónde corre? ¿Cuáles de los tres poderes tiene?



Enjambres y Hugging Face

BLOQUE 5 DE 7 · **15 MIN**



Muchos agentes a la vez

Muchos agentes a la vez: qué cambia



Un resultado malo pasa de un agente al siguiente, y cada uno lo da por bueno.

Un agente que revisa a otro agente no cuenta como verificación.

El error se copia

Un agente toma como verificado lo que otro no verificó.

La instrucción ajena circula

Lo que leyó uno llega como orden a los demás.

El gasto se dispara

Cien agentes consumen cien veces, y de noche.

Nadie lee todo

Miles de acciones por hora no las sigue una persona.

Los controles

Entorno aislado, sin acceso a producción.

Tope de agentes, de tiempo y de gasto.

Un responsable que lo puede detener, y sabe cómo.



Hugging Face, julio de 2026

Un video de dos minutos, de la Televisión Pública.

Mirá **dónde estaba el agente** cuando empezó, y **qué buscaba**.




El caso, en cinco fechas

Hugging Face, julio de 2026: el caso en cinco fechas



TRES REGLAS DE LA SESIÓN, EN UN SOLO CASO



Fuente: los dos comunicados de Hugging Face (16 y 27 de julio de 2026). La cantidad de agentes varía según quién lo cuente.

El entorno aislado es un control,
y puede fallar: **se suma** a los
permisos mínimos y al registro



Los atacantes también tienen IA

BLOQUE 6 DE 7 · **10 MIN**



Qué cambia cuando ataca alguien con IA

- **El engaño es más creíble:** un correo sin errores, una voz o una cara imitadas
- **Atacar requiere menos oficio:** el modelo orienta a quien no conoce la industria
- **Las fallas se encuentran más rápido:** menos tiempo entre que se publica y que se usa



Lo que se hace distinto desde el lunes

- **Segundo canal** para pagos, datos bancarios, credenciales y pedidos urgentes
- La voz y la imagen **no alcanzan** como prueba de identidad
- El correo sospechoso **se reporta**, aunque esté bien escrito



El loop supone que equivocarse es barato

Ayer: el error vuelve y se corrige. Funciona porque leer y calcular son **reversibles**.

En un sistema que opera equipos, un paso equivocado termina en una **válvula en la posición que no era**.



Entre el modelo y el campo, **una
persona con nombre y apellido**



La política

BLOQUE 7 DE 7 · **15 MIN**



Quién responde ya tiene respuesta

Air Canada, 2024: su chatbot **inventó una política de descuentos** y un tribunal obligó a la aerolínea a cumplirla.

Para el tribunal, lo que dijo el chatbot lo dijo la empresa.



Del riesgo al control

Del riesgo al control: la política en una mirada

LO QUE PUEDE PASAR	LO QUE LO FRENA	SECCIÓN
Un dato confidencial termina afuera	Mapa de tres niveles y herramientas aprobadas	4 y 5
Un dato inventado sale en un informe firmado	Verificación según el destino del texto	6
La herramienta se cae, o el equipo ya no sabe hacerlo	Plan B por tarea crítica	8
Un agente borra o manda lo que no debía	Entorno aislado, permisos mínimos, regla de dos	9
Toman una cuenta a través del correo	Sin agentes en la casilla; segundo factor sin correo	10
Un sistema de muchos agentes se desborda	Topes, entorno aislado y un responsable con corte	12
Un pedido falso con voz o cara conocida	Confirmación por un segundo canal	13

Ningún riesgo de la lista se resuelve prohibiendo la herramienta. Todos tienen un control que deja seguir usándola.

La política, en dos versiones

La larga, 1.0: dieciséis secciones y cuatro anexos. Cada una dice qué se habilita, qué riesgo cubre y cuál es la regla. Es la que se discute con sistemas, legales y la gerencia.

La de una página, 0.2: seis puntos. Es la que se pega al lado del monitor.



Para llevarse

- Antes de pegar un dato, **ubicalo en su nivel**; y anotá en el relevamiento lo que ya usás
- **Verificá según el costo del error**, y escribí el **plan B** de tu tarea crítica
- Un agente corre **aislado**, con los permisos justos, y **no entra al correo**



Pausa · 10 min

A LAS **12:00** (10:00 EN ECUADOR Y COLOMBIA) SIGUE LA **SESIÓN 8**, CON SU PROPIO DECK:
EL CASO Y EL HORIZONTE

